

# AIF – Domain Bổ Sung: AWS AI Services, Bedrock, SageMaker & Prompt Engineering

## PHẦN 1: AWS Managed AI Services – Dịch Vụ AI Có Sẵn

**Bản chất:** Pre-trained ML services – **không cần kinh nghiệm ML**, chỉ cần gọi API. Tính tiền Pay-as-you-go.

### 1.1 Nhóm Xử Lý Ngôn Ngữ & Văn Bản (NLP)

| Dịch vụ                  | Chức năng                                                                              | Tính năng nổi bật                                                                                   |
|--------------------------|----------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| <b>Amazon Comprehend</b> | Phân tích văn bản – tìm cảm xúc (sentiment), cụm từ chính, NER (tên người, địa danh)   | Custom Classification · Custom Entity Recognition (thuật ngữ doanh nghiệp)                          |
| <b>Amazon Translate</b>  | Dịch thuật ngôn ngữ tự nhiên                                                           | Bản địa hóa nội dung ứng dụng                                                                       |
| <b>Amazon Textract</b>   | Trích xuất văn bản + <b>cấu trúc bảng &amp; biểu mẫu (key-value)</b> từ ảnh quét / PDF | ⚠ <b>Bẫy thi:</b> Hóa đơn, hồ sơ y tế dạng bản quét → chọn <b>Textract</b> , không phải Rekognition |

### 1.2 Nhóm Âm Thanh (Speech)

| Dịch vụ                  | Chiều         | Tính năng quan trọng                                                     |
|--------------------------|---------------|--------------------------------------------------------------------------|
| <b>Amazon Transcribe</b> | Speech → Text | PII Redaction · Toxicity Detection · Custom Vocabulary                   |
| <b>Amazon Polly</b>      | Text → Speech | Lexicons (cách phát âm từ viết tắt) · SSML (điều chỉnh nhấn nhá, tốc độ) |

### 1.3 Nhóm Thị Giác Máy Tính (Vision)

**Amazon Rekognition** – phân tích hình ảnh & video:

- Content Moderation – lọc ảnh nhạy cảm
- Celebrity Recognition – nhận diện người nổi tiếng
- **Face Liveness** – phân biệt mặt thật vs ảnh chụp / video giả
- **Custom Labels** – nhận diện logo, sản phẩm riêng của doanh nghiệp (chỉ cần vài trăm ảnh mẫu)

### 1.4 Nhóm Phân Tích & Gợi Ý

| Dịch vụ            | Chức năng                                                       | Từ khóa thi                                             |
|--------------------|-----------------------------------------------------------------|---------------------------------------------------------|
| Amazon Personalize | Gợi ý sản phẩm / nội dung cá nhân hóa (như Amazon.com, Netflix) | <i>recommendations, suggest products</i>                |
| Amazon Forecast    | Dự báo chuỗi thời gian (time-series) – tồn kho, doanh thu       | <i>predict future quantity, time-series forecasting</i> |

 **Bẫy thi:** "Gợi ý mua hàng" → **Personalize** · "Dự báo số lượng tháng sau" → **Forecast**

1.5 Nhóm Tìm Kiếm & Hội Thoại

| Dịch vụ       | Chức năng                                               | Thành phần chính                                                                |
|---------------|---------------------------------------------------------|---------------------------------------------------------------------------------|
| Amazon Lex    | Xây dựng Chatbot (text + voice) – cùng công nghệ Alexa  | Intents (ý định) · Slots (thông tin cần thu thập) · Lambda (thực thi hành động) |
| Amazon Kendra | Tìm kiếm doanh nghiệp thông minh bằng ngôn ngữ tự nhiên | Tìm trong hàng ngàn tài liệu nội bộ, hiểu ngữ nghĩa                             |

1.6 Nhóm Chuyên Biệt

| Dịch vụ                                 | Chức năng                                                                                            |
|-----------------------------------------|------------------------------------------------------------------------------------------------------|
| Comprehend Medical / Transcribe Medical | Thuật ngữ y khoa, tuân thủ <b>HIPAA</b>                                                              |
| Amazon A2I (Augmented AI)               | Khi AI có <b>độ tự tin thấp (low confidence)</b> → tự động chuyển sang <b>con người kiểm tra lại</b> |
| AWS Trainium (Trn1)                     | Phần cứng chuyên <b>huấn luyện (training)</b> mô hình lớn – giảm 50% chi phí vs GPU                  |
| AWS Inferentia (Inf1/Inf2)              | Phần cứng chuyên <b>chạy dự đoán (inference)</b> – tăng tốc & giảm 70% chi phí                       |
| SageMaker Ground Truth                  | <b>Con người dán nhãn dữ liệu</b> – nhân viên nội bộ / bên thứ 3 / Amazon Mechanical Turk            |

1.7 Bảng Tra Cứu Nhanh – Chọn Service Trong 5 Giây

| Từ khóa trong đề                     | Chọn               |
|--------------------------------------|--------------------|
| Text analysis, sentiment, NER        | <b>Comprehend</b>  |
| Speech-to-text, PII removal in audio | <b>Transcribe</b>  |
| Text-to-speech, SSML, lexicons       | <b>Polly</b>       |
| Images, faces, unsafe content        | <b>Rekognition</b> |
| Forms, tables, document extraction   | <b>Textract</b>    |

| Từ khóa trong đề                    | Chọn                |
|-------------------------------------|---------------------|
| Chatbots, intents, slots            | <b>Lex</b>          |
| Enterprise search, semantic search  | <b>Kendra</b>       |
| Recommendations (gợi ý sản phẩm)    | <b>Personalize</b>  |
| Time-series forecasting (dự báo)    | <b>Forecast</b>     |
| Human review for predictions        | <b>A2I</b>          |
| Data labeling / RLHF                | <b>Ground Truth</b> |
| Training cost reduction (hardware)  | <b>Trainium</b>     |
| Inference cost reduction (hardware) | <b>Inferentia</b>   |

## PHẦN 2: Amazon Bedrock – Nền Tảng Foundation Model

### 2.1 Tổng Quan

| Đặc điểm             | Chi tiết                                                |
|----------------------|---------------------------------------------------------|
| <b>Fully Managed</b> | Không cần quản lý hạ tầng                               |
| <b>Unified API</b>   | 1 API duy nhất gọi tất cả models                        |
| <b>Pay-per-use</b>   | Dùng bao nhiêu trả bấy nhiêu                            |
| <b>Data Privacy</b>  | ⚠ Dữ liệu <b>KHÔNG BAO GIỜ</b> rời khỏi account của bạn |

### 2.2 6 Tính Năng Cốt Lõi

Playground → Fine-tuning → RAG/Knowledge Bases → Agents → Guardrails → FM Evaluation

### 2.3 Foundation Models – Các Nhà Cung Cấp

| Nhà cung cấp        | Dòng model                                  | Điểm mạnh                              |
|---------------------|---------------------------------------------|----------------------------------------|
| <b>Amazon</b>       | Titan Text · Titan Embeddings · Titan Image | Responsible AI tích hợp sẵn            |
| <b>Anthropic</b>    | Claude 3 (Haiku / Sonnet / Opus)            | Context window lớn · Suy luận phức tạp |
| <b>Meta</b>         | Llama 2, Llama 3                            | Open weights – tùy chỉnh sâu           |
| <b>AI21 Labs</b>    | Jurassic-2                                  | Đa ngôn ngữ                            |
| <b>Cohere</b>       | Command · Embed                             | Embedding chuyên biệt                  |
| <b>Stability AI</b> | Stable Diffusion                            | Sinh ảnh từ văn bản                    |
| <b>Mistral</b>      | Mistral                                     | Nhỏ nhưng hiệu suất cao                |

## 2.4 RAG & Knowledge Bases – Chi Tiết Kỹ Thuật

### Luồng xử lý RAG:

```
Files → Chunking → Embeddings → Vector DB
                                ↑
User hỏi → Search & Retrieve → Ghép Prompt → LLM → Trả lời
```

**Nguồn dữ liệu:** Amazon S3 · Confluence · Microsoft SharePoint · Salesforce · Web Crawler

### Vector Database cho RAG:

| DB                                  | Khi nào dùng                             |
|-------------------------------------|------------------------------------------|
| <b>Amazon OpenSearch Serverless</b> | Mặc định · hiệu suất cao · real-time KNN |
| <b>Amazon DocumentDB</b>            | NoSQL (MongoDB) · real-time              |
| <b>Amazon Aurora</b>                | Đang dùng sẵn PostgreSQL/MySQL           |
| <b>Amazon Neptune</b>               | Graph-based (dữ liệu quan hệ phức tạp)   |
| <b>Pinecone</b>                     | Managed vector DB bên thứ 3              |
| <b>Redis</b>                        | In-memory · độ trễ cực thấp              |

💡 **Embedding model** có thể **khác** với Foundation model (VD: dùng Titan Embeddings để embed, Claude để generate)

## 2.5 Agents – "Nghĩ + Hành Động"

**Công thức:** Agent = Model + Action Groups + Knowledge Bases

| Model                 | Agent                                       |
|-----------------------|---------------------------------------------|
| Khả năng Chỉ trả lời  | <b>Nghĩ + Hành động</b> + tác động hệ thống |
| Ví dụ Trả lời câu hỏi | Gọi API, đọc/ghi DB, deploy tài nguyên      |

**Cơ chế hoạt động:** Phân tích → Lên kế hoạch (CoT) → Gọi Action Groups → Tổng hợp **Tracing:** Theo dõi từng bước Agent nghĩ & làm để debug

## 2.6 Fine-tuning – Phân Biệt 5 Phương Pháp

| Phương pháp               | Dữ liệu | Thay đổi weights? | Dùng khi               |
|---------------------------|---------|-------------------|------------------------|
| <b>Prompt Engineering</b> | Không   | ✗                 | Thay đổi output format |

| Phương pháp               | Dữ liệu                   | Thay đổi weights? | Dùng khi                             |
|---------------------------|---------------------------|-------------------|--------------------------------------|
| RAG                       | Tài liệu ngoài            | ✗                 | Cần dữ liệu mới/trích dẫn            |
| Instruction Fine-tuning   | Labeled (Prompt-Response) | ✓                 | Đổi tone, behavior, persona          |
| Continued Pre-training    | Unlabeled (văn bản thô)   | ✓                 | Học từ viết tắt, thuật ngữ ngành sâu |
| Reinforcement Fine-tuning | Rewards                   | ✓                 | Tối ưu tác vụ cụ thể                 |

 **Bắt buộc nhớ:** Đã Fine-tune → **BẮT BUỘC** dùng gói giá **Provisioned Throughput**

2.7 Pricing – 3 Mô Hình Tính Giá

| Mô hình                | Đặc điểm                           | Dùng khi                                    |
|------------------------|------------------------------------|---------------------------------------------|
| On-Demand              | Trả theo token, không cam kết      | Workload không đoán trước                   |
| Batch Mode             | Xử lý offline, <b>giảm giá 50%</b> | Không cần real-time                         |
| Provisioned Throughput | Mua khoán năng lực                 | Workload ổn định · <b>Fine-tuned models</b> |

Quy tắc token:

1 token ≈ 4 ký tự tiếng Anh

Tính tiền: Input Tokens (Prompt + RAG) + Output Tokens (câu trả lời)

Mẹo tiết kiệm: Prompt ngắn · Output ngắn · Model nhỏ hơn · Batch mode

2.8 FM Evaluation Metrics

| Metric     | Dùng cho             | Ghi nhớ                             |
|------------|----------------------|-------------------------------------|
| ROUGE      | Tóm tắt & Dịch thuật | Recall-oriented                     |
| BLEU       | Dịch máy chuyên biệt | Exact-match n-grams                 |
| BERTScore  | Semantic similarity  | Hiểu nghĩa, không cần từ giống nhau |
| Perplexity | Độ tự tin dự đoán    | Càng thấp càng tốt                  |

2.9 Cây Quyết Định Bedrock

| Tình huống                    | Giải pháp                    |
|-------------------------------|------------------------------|
| Cần kết nối dữ liệu bên ngoài | <b>RAG / Knowledge Bases</b> |

| Tình huống                                | Giải pháp                      |
|-------------------------------------------|--------------------------------|
| Cần model thực hiện actions (gọi API)     | <b>Agents</b>                  |
| Cần kiểm soát / chặn nội dung             | <b>Guardrails</b>              |
| Cần model học hành vi / kiến thức mới     | <b>Fine-tuning</b>             |
| Có dữ liệu Prompt-Response (labeled)      | <b>Instruction Fine-tuning</b> |
| Chỉ có dữ liệu thô (unlabeled)            | <b>Continued Pre-training</b>  |
| Data thay đổi thường xuyên / cần citation | <b>RAG</b>                     |
| Đổi tone / giọng văn / behavior           | <b>Instruction Fine-tuning</b> |

## PHẦN 3: Amazon Q – Hệ Sinh Thái Trợ Lý AI

### 3.1 Tổng Quan Hệ Sinh Thái

|                     |                                                   |
|---------------------|---------------------------------------------------|
| Amazon Q Business   | → Nhân viên nội bộ + dữ liệu công ty              |
| Amazon Q Developer  | → Lập trình viên + quản lý AWS                    |
| Amazon Q Apps       | → Tạo app No-Code từ dữ liệu nội bộ               |
| Amazon Q (Services) | → QuickSight · EC2 · AWS Chatbot                  |
| PartyRock           | → Playground thử nghiệm (KHÔNG phải service thật) |

### 3.2 Amazon Q Business

**Mục tiêu:** Trợ lý GenAI cho nhân viên nội bộ, dùng dữ liệu công ty

| Thành phần                       | Chi tiết                                                                                                                                                                      |
|----------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Data</b><br><b>Connectors</b> | 40+ nguồn: S3 · RDS · Aurora · Microsoft 365 · Salesforce · Google Drive · Slack · SharePoint                                                                                 |
| <b>Plugins</b>                   | Jira · ServiceNow · Zendesk – AI có thể <b>TẠO, SỬA, XÓA</b> dữ liệu trong app bên thứ 3                                                                                      |
| <b>Authentication</b>            |  <b>BẮT BUỘC</b> dùng <b>IAM Identity Center</b> (hoặc External IDP: Google, Microsoft AD) |
| <b>Admin Controls</b>            | Blocked Topics · Internal Only · PII Protection · Content Filters                                                                                                             |

### 3.3 Amazon Q Developer

**2 chức năng chính:**

| Chức năng                    | Mô tả                                                                |
|------------------------------|----------------------------------------------------------------------|
| <b>AWS Account Assistant</b> | Liệt kê tài nguyên · Gợi ý CLI · Phân tích chi phí · Troubleshooting |

| Chức năng                | Mô tả                                                                         |
|--------------------------|-------------------------------------------------------------------------------|
| <b>AI Code Companion</b> | Code Generation · Code Completion · Security Scan · Debugging · Documentation |

**Hỗ trợ:** Java · JavaScript · Python · TypeScript · C# · IDE: VS Code · Visual Studio · JetBrains

**Khác GitHub Copilot:** Q Developer tích hợp tài khoản AWS + gợi ý lệnh CLI

### 3.4 Amazon Q Apps

- **No-Code:** Tạo app bằng ngôn ngữ tự nhiên, không cần viết code
- Dùng **dữ liệu nội bộ công ty** + tích hợp Plugins
- Cần **tài khoản AWS**

### 3.5 PartyRock

⚠ **KHÔNG PHẢI dịch vụ AWS thật** – chỉ là Playground

|                 | PartyRock          | Q Apps         |
|-----------------|--------------------|----------------|
| Tài khoản AWS   | ❌ Không cần        | ✅ Cần          |
| Dữ liệu công ty | ❌ Không            | ✅ Có           |
| Backend         | Amazon Bedrock     | Amazon Bedrock |
| Mục đích        | Thử nghiệm cá nhân | Công việc thật |

### 3.6 Cây Quyết Định Amazon Q

| Tình huống                                 | Chọn                                |
|--------------------------------------------|-------------------------------------|
| Nhân viên + dữ liệu nội bộ + chat          | <b>Q Business</b>                   |
| Tạo app nội bộ không cần code              | <b>Q Apps</b>                       |
| Lập trình viên + code + quản lý AWS        | <b>Q Developer</b>                  |
| Thử nghiệm không cần tài khoản             | <b>PartyRock</b>                    |
| Dashboard / biểu đồ                        | <b>Q for QuickSight</b>             |
| Kiểm soát toàn diện, chọn model, fine-tune | <b>Bedrock</b> (thay vì Q Business) |

## PHẦN 4: Amazon SageMaker – Nền Tảng ML All-in-One

**Định nghĩa:** Fully managed · Dành cho Developers & Data Scientists · Build → Train → Deploy

### 4.1 Core Features

| Tính năng                    | Chức năng                                                       |
|------------------------------|-----------------------------------------------------------------|
| SageMaker Studio             | IDE trung tâm: code · debug · deploy · tự động hóa              |
| Automatic Model Tuning (AMT) | Tự động tìm <b>best hyperparameters</b> · Hỗ trợ early stopping |

4.2 Data Tools

| Tool          | Chức năng                                                                           | Từ khóa thi                             |
|---------------|-------------------------------------------------------------------------------------|-----------------------------------------|
| Data Wrangler | Chuẩn bị · Làm sạch · Biến đổi dữ liệu (Feature Engineering) trước khi train        | <i>prepare, cleanse, transform data</i> |
| Feature Store | Kho lưu trữ trung tâm – <b>lưu trữ &amp; tái sử dụng features</b> giữa nhiều models | <i>store, share, reuse features</i>     |

4.3 Models & Humans

| Tool              | 3 Chức Năng Chính                                                                       | Từ khóa thi                                             |
|-------------------|-----------------------------------------------------------------------------------------|---------------------------------------------------------|
| SageMaker Clarify | ① Model Evaluation · ② Explainability (tại sao mô hình dự đoán thế?) · ③ Bias Detection | <i>detect bias, explain predictions, compare models</i> |
| Ground Truth      | Con người dán nhãn dữ liệu (RLHF)                                                       | <i>human labeling, data annotation</i>                  |

4.4 Governance & MLOps

| Tool            | Chức năng                                                                             | Từ khóa thi                             |
|-----------------|---------------------------------------------------------------------------------------|-----------------------------------------|
| Model Cards     | Ghi chép tài liệu về mô hình (mục đích, rủi ro, training)                             | <i>document model</i>                   |
| Model Dashboard | Tổng quan TẤT CẢ mô hình đang có                                                      | <i>view all models</i>                  |
| Model Registry  | Quản lý <b>phiên bản &amp; trạng thái phê duyệt</b> trước khi lên production          | <i>version control, approval status</i> |
| Model Monitor   | Giám sát chất lượng <b>KHI ĐANG CHẠY THỰC TẾ</b> · Phát hiện Model Drift & Bias Drift | <i>detect drift in production</i>       |
| Pipelines       | CI/CD cho ML – tự động hóa toàn bộ quy trình                                          | <i>automate ML workflow</i>             |
| Role Manager    | Phân quyền theo vị trí (Data Scientist, MLOps Engineer)                               | —                                       |

4.5 Deployment – Phân Biệt 4 Loại

|         | Real-Time | Serverless         | Asynchronous  | Batch Transform |
|---------|-----------|--------------------|---------------|-----------------|
| Latency | Thấp      | Thấp (Cold Start!) | Gần real-time | Cao             |



|          | Real-Time    | Serverless               | Asynchronous | Batch Transform               |
|----------|--------------|--------------------------|--------------|-------------------------------|
| Payload  | < 6MB        | < 6MB                    | < 1GB        | Không giới hạn                |
| Infra    | Tự quản lý   | AWS lo hết               | Tự quản lý   | Tự quản lý                    |
| Use case | Chatbot, API | Traffic lúc có lúc không | File lớn     | Xử lý offline tập dữ liệu lớn |

4.6 Phân Biệt Các Tool Để Nhầm

| Cặp dễ nhầm                    | Phân biệt                                                           |
|--------------------------------|---------------------------------------------------------------------|
| Data Wrangler vs Feature Store | Wrangler: chế biến dữ liệu · Feature Store: lưu & tái sử dụng       |
| Model Cards vs Model Registry  | Cards: viết tài liệu · Registry: lưu version & phê duyệt            |
| Model Monitor vs Clarify       | Clarify: phân tích trước khi chạy · Monitor: giám sát khi đang chạy |
| Clarify vs Ground Truth        | Clarify: công cụ tự động/metrics · Ground Truth: sức con người      |

4.7 Từ Khóa → Đáp Án SageMaker

| Từ khóa                                | Chọn                   |
|----------------------------------------|------------------------|
| Automate ML workflow                   | Pipelines              |
| Store features for reuse               | Feature Store          |
| Detect model drift in production       | Model Monitor          |
| Detect bias / Explain / Compare models | Clarify                |
| Human labeling / RLHF                  | Ground Truth           |
| Tune hyperparameters automatically     | AMT                    |
| Large payload / 1GB file               | Asynchronous Inference |
| No infrastructure / Occasional traffic | Serverless Inference   |

PHẦN 5: Prompt Engineering – Kỹ Thuật Tối Ưu Câu Lệnh

5.1 Cấu Trúc Prompt Chuẩn (4 Thành Phần)

INSTRUCTIONS

CONTEXT

INPUT DATA

OUTPUT FORMAT

← Bắt buộc: làm gì, cách nào

← Tùy chọn: bối cảnh, nền

← Tùy chọn: dữ liệu cần xử lý

← Bắt buộc: định dạng, độ dài

5.2 Các Kỹ Thuật Prompt – Phân Nhóm

Nhóm 1: Kỹ Thuật Cơ Bản

| Kỹ thuật                 | Cách dùng                                    | Khi nào dùng                          |
|--------------------------|----------------------------------------------|---------------------------------------|
| Zero-shot                | Hỏi thẳng, không ví dụ                       | Tác vụ đơn giản, kiến thức phổ thông  |
| Few-shot (One-shot)      | Cho 2–3 ví dụ cặp input-output rồi mới hỏi   | AI trả lời sai format (JSON, CSV...)  |
| Role / Persona Prompting | "Hãy đóng vai một chuyên gia bảo mật AWS..." | Thiết lập tone, từ vựng chuyên nghiệp |

Nhóm 2: Tối Ưu Suy Luận

| Kỹ thuật               | Cơ chế                                                                        | Khi nào dùng                         |
|------------------------|-------------------------------------------------------------------------------|--------------------------------------|
| Chain of Thought (CoT) | Câu thần chú: <i>"Think step by step"</i> – ép AI viết từng bước              | Bài toán logic, toán học             |
| Self-Consistency       | Sinh câu trả lời nhiều lần → chọn đáp án xuất hiện nhiều nhất (Majority vote) | Logic phức tạp, cần độ chính xác cao |
| Generated Knowledge    | Bước 1: AI sinh kiến thức về chủ đề · Bước 2: Dùng kiến thức đó để trả lời    | Giảm ảo giác (hallucination)         |

Nhóm 3: Nâng Cao & Cấu Trúc

| Kỹ thuật               | Cơ chế                                                                                    |
|------------------------|-------------------------------------------------------------------------------------------|
| Tree of Thoughts (ToT) | Nhiều nhánh giải pháp → tự đánh giá → backtrack nếu sai. Dùng cho cờ, kế hoạch chiến lược |
| ReAct                  | Suy nghĩ → Hành động (dùng tool) → Quan sát → Suy nghĩ tiếp. Cốt lõi của <b>AI Agents</b> |
| Directional Stimulus   | Cung cấp "gợi ý từ khóa" định hướng kèm theo đầu vào                                      |

Nhóm 4: Điều Hướng & Giới Hạn

| Kỹ thuật           | Cơ chế                                                                       | Ví dụ                                                                        |
|--------------------|------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| Negative Prompting | Liệt kê rõ những gì AI <b>KHÔNG</b> được làm                                 | <i>"Không dùng từ 'đột phá'. Không dùng dấu chấm than. Không quá 3 câu."</i> |
| Least-to-Most      | Chia bài toán lớn thành câu hỏi nhỏ, kết quả bước trước làm đầu vào bước sau | Giải toán nhiều bước phức tạp                                                |

Nhóm 5: Nặng Đò (Dành cho Lập Trình & Agent)

| Kỹ thuật                       | Cơ chế                                                                           |
|--------------------------------|----------------------------------------------------------------------------------|
| <b>Meta Prompting / APE</b>    | Dùng AI viết và tối ưu prompt thay cho con người                                 |
| <b>PAL / PoT</b>               | AI viết code Python để giải toán → chạy code lấy kết quả (không tự tính)         |
| <b>Graph of Thoughts (GoT)</b> | Nâng cấp ToT: các nhánh suy nghĩ có thể <b>đan chéo, gộp lại</b> với nhau        |
| <b>Active-Prompt</b>           | Hệ thống đo uncertainty → chọn câu AI bối rối nhất → con người viết few-shot mẫu |

### 5.3 Inference Parameters – Tổng Hợp

| Tham số                    | Phạm vi   | Thấp               | Cao               | Ảnh hưởng Latency? |
|----------------------------|-----------|--------------------|-------------------|--------------------|
| <b>Temperature</b>         | 0.0 – 1.0 | Chính xác, lặp lại | Sáng tạo, đa dạng | ❌ KHÔNG            |
| <b>Top-P</b>               | 0 – 1     | Chọn ít từ         | Chọn nhiều từ     | ❌ KHÔNG            |
| <b>Top-K</b>               | Số nguyên | Ít lựa chọn        | Nhiều lựa chọn    | ❌ KHÔNG            |
| <b>Max Length (tokens)</b> | —         | Output ngắn        | Output dài        | ✅ CÓ               |

⚠️ **Bẫy cực nặng trong thi:** Temperature / Top-P / Top-K **KHÔNG** ảnh hưởng đến Latency. Latency chỉ bị ảnh hưởng bởi **kích thước model** và **số lượng token (input + output)**.

### 5.4 Câu Quyết Định Prompt Engineering

| Tình huống                     | Kỹ thuật                                                                      |
|--------------------------------|-------------------------------------------------------------------------------|
| Cần output theo format cụ thể  | <b>Few-shot</b>                                                               |
| Giải logic / toán phức tạp     | <b>Chain of Thought</b>                                                       |
| Tránh nội dung không mong muốn | <b>Negative Prompting</b>                                                     |
| Cần độ chính xác cao, thực tế  | <b>Temperature thấp (0.0–0.3)</b>                                             |
| Cần sáng tạo, đa dạng          | <b>Temperature cao (0.7–1.0)</b>                                              |
| Giảm latency                   | <b>Giảm tokens</b> (prompt ngắn + output ngắn) hoặc dùng <b>model nhỏ hơn</b> |
| Muốn AI thực hiện hành động    | <b>ReAct</b>                                                                  |
| AI tự tạo & tối ưu prompt      | <b>APE / Meta Prompting</b>                                                   |

### 5.5 Từ Khóa Vàng – Phần Prompt Engineering

| Từ khóa trong đề                 | Đáp án                                              |
|----------------------------------|-----------------------------------------------------|
| No example, trả lời thẳng        | <b>Zero-shot</b>                                    |
| 2–3 examples, làm theo mẫu       | <b>Few-shot</b>                                     |
| Tránh ảo giác, trả lời thực tế   | <b>Temperature thấp</b>                             |
| Không đề cập technical terms     | <b>Negative Prompting</b>                           |
| Giải toán / lập luận phức tạp    | <b>Chain of Thought</b>                             |
| Bài toán chia nhỏ từng bước      | <b>Least-to-Most</b>                                |
| AI dùng tool, tương tác hệ thống | <b>ReAct / Agents</b>                               |
| Latency cao / chạy chậm          | Giảm <b>số token</b> – KHÔNG phải chỉnh Temperature |

## Master Cheat Sheet – Bảng Tổng Hợp Cuối

### RAG vs Fine-tuning

|                   | <b>RAG</b>                               | <b>Fine-tuning</b>                      |
|-------------------|------------------------------------------|-----------------------------------------|
| Thay đổi weights? | ✗                                        | ✓                                       |
| Dữ liệu cần       | Tài liệu ngoài                           | Training data có nhãn / thô             |
| Chi phí           | Rẻ hơn                                   | Đắt hơn                                 |
| Dùng khi          | Dữ liệu mới, cần citation, chống ảo giác | Đổi behavior, tone, học thuật ngữ ngành |

### Comprehend vs Lex vs Kendra

|          | <b>Comprehend</b>        | <b>Lex</b>                     | <b>Kendra</b>             |
|----------|--------------------------|--------------------------------|---------------------------|
| Mục đích | Phân tích văn bản có sẵn | Xây chatbot nói chuyện qua lại | Tìm kiếm tài liệu nội bộ  |
| Input    | Văn bản tĩnh             | Hội thoại                      | Câu hỏi ngôn ngữ tự nhiên |

### Clarify vs Monitor vs Ground Truth

|           | <b>Clarify</b>          | <b>Model Monitor</b>               | <b>Ground Truth</b> |
|-----------|-------------------------|------------------------------------|---------------------|
| Thời điểm | <b>Trước</b> khi deploy | <b>Sau</b> khi deploy (production) | Thu thập nhãn       |
| Công cụ   | Tự động / Metrics       | Tự động / Alerts                   | Con người           |
| Chức năng | Bias + Explainability   | Drift detection                    | Data labeling       |

 Tài liệu ôn tập AIF – Phần bổ sung: AWS AI Services · Bedrock · Amazon Q · SageMaker · Prompt Engineering