



AIF – Domain 3: Tùy Chỉnh, Đánh Giá & Triển Khai AI

1. Phân Cấp Tùy Chỉnh – Customization Hierarchy

🚦 Nhớ thứ tự: từ **dễ** → **khó**, từ **rẻ** → **đắt**

Cấp độ 1	→	Prompt Engineering	(Không thay đổi mô hình)
Cấp độ 2	→	RAG	(Inject dữ liệu ngoài tại Inference)
Cấp độ 3	→	Fine-Tuning	(Dạy lại trên dữ liệu chuyên biệt)
Cấp độ 4	→	Pre-Training	(Train từ đầu - cực đắt, hiếm khi dùng)

Cấp độ	Phương pháp	Khi nào dùng	Chi phí
1	Prompt Engineering	Muốn thay đổi định dạng câu trả lời ngay lập tức	Thấp nhất
2	RAG	Cần cập nhật thông tin mới nhất mà không train lại	Vừa
3	Fine-Tuning	Prompt + RAG không đủ; cần hiểu thuật ngữ/phong cách chuyên biệt (y khoa, luật...)	Cao
4	Pre-Training	Train mô hình từ đầu hoàn toàn	Cực đắt – ❌ hiếm là đáp án đúng trong thi

2. Kỹ Thuật Prompt Nâng Cao

Các chiến lược Prompting

Kỹ thuật	Mô tả	Khi nào dùng
Zero-shot	Không có ví dụ mẫu, hỏi thẳng	Câu hỏi đơn giản, mô hình đủ mạnh
Few-shot	Cung cấp 2–3 ví dụ mẫu trong prompt	AI trả lời sai định dạng (JSON, bảng...) → đây là đáp án thi phổ biến
Chain of Thought (CoT)	Yêu cầu AI suy luận từng bước	Bài toán logic, toán học · Câu lệnh: <i>"Let's think step by step"</i>
Persona Prompting	Giao vai diễn cho AI	Thu hẹp không gian phản hồi, trả lời chuyên nghiệp hơn · VD: <i>"Hãy đóng vai chuyên gia bảo mật AWS"</i>

Tham số Prompt nâng cao

Tham số	Cách hoạt động	Lưu ý
Temperature	Điều chỉnh độ ngẫu nhiên	—
Top-P (Nucleus Sampling)	Chọn từ trong nhóm có tổng xác suất = P	—
Top-K	Chọn trong K từ có xác suất cao nhất	—
Stop Sequences	Chuỗi ký tự (VD: ###) ra lệnh dừng tạo văn bản	—

⚠️ **Quan trọng:** Temperature, Top-P, Top-K **không ảnh hưởng đến Latency (độ trễ)**. Latency chỉ bị ảnh hưởng bởi **kích thước mô hình** và **số lượng token**.

3. Vector Databases trên AWS – Phân Biệt Dịch Vụ

Dịch vụ AWS	Khi nào dùng	Đặc điểm
Amazon OpenSearch Service	Lựa chọn phổ biến nhất cho tìm kiếm vector	Tìm kiếm toàn diện, scalable
Amazon Aurora + pgvector	Đã có sẵn database PostgreSQL	Tích hợp vector search vào DB hiện có
Amazon Neptune Analytics	Dữ liệu có quan hệ phức tạp	Chuyên cho Graph data
Amazon S3	Lưu trữ dữ liệu thô ban đầu	Đóng vai trò Data Source trước khi Chunking & đưa vào Vector DB

4. Các Chỉ Số Đánh Giá – Evaluation Metrics

📁 Nhóm 1: Phân Loại (Classification Metrics)

Dùng khi: Dự đoán đối tượng thuộc **nhãn** nào (Chó/Mèo, Spam/Không spam, Rời bỏ/Không rời bỏ...)

Chỉ số	Tập trung vào	Keywords thi	Use case
Confusion Matrix	Bảng chi tiết TP/FP/TN/FN	<i>detailed insights, classification errors, identify where model confuses</i>	Nhìn sâu vào điểm mô hình nhầm lẫn – không phải một con số tổng quát
Precision	Giảm thiểu False Positive (FP)	<i>minimize false positives, cost of false alarm is high</i>	Bộ lọc Spam: thà để lọt thư rác vào inbox hơn đưa nhầm email hợp đồng vào thùng rác
Recall	Giảm thiểu False Negative (FN)	<i>minimize false negatives, identify all instances, high cost of missing</i>	Chẩn đoán ung thư, phát hiện xâm nhập mạng – thà báo nhầm còn hơn bỏ lọt
F1 Score	Cân bằng Precision & Recall	<i>imbalanced data, binary classification, customer churn</i>	Phát hiện gian lận thẻ tín dụng (0.1% giao dịch là gian lận)

 Nhóm 2: Hồi Quy (Regression Metrics)

Dùng khi: Dự đoán **con số cụ thể, liên tục** (Giá nhà, Nhiệt độ, Doanh thu...)

Chỉ số	Đặc điểm	Keywords thi	Use case
MAE (Mean Absolute Error)	Ít bị ảnh hưởng bởi outliers	<i>average error, absolute differences, robust to outliers</i>	Dự báo thời tiết – đo sai số trung bình chung
RMSE (Root Mean Squared Error)	Nhạy cảm với sai lệch lớn (bình phương sai số)	<i>penalize large errors, sensitive to outliers</i>	Dự đoán lực kéo máy bay – sai lệch lớn gây hậu quả nghiêm trọng

 Nhóm 3: AI Tạo Sinh & NLP (Generative AI & NLP Metrics)

Dùng khi: Làm việc với **văn bản** hoặc **hình ảnh**

Chỉ số	Đặc điểm	Keywords thi	Use case
BLEU	So khớp từ vựng chính xác (exact-match n-grams)	<i>machine translation, translate manual/documents, bilingual</i>	Đánh giá hệ thống dịch thuật Anh → Việt
ROUGE	Tập trung vào Recall – AI có bao quát hết ý chính không	<i>text summarization, gisting, recall-oriented</i>	Đánh giá tính năng "Tóm tắt bài báo"
BERTScore	Đo tương đồng ngữ nghĩa – không cần từ giống nhau	<i>semantic similarity, creative spelling, shortened words, phrasing differently</i>	Chatbot với tuổi teen dùng teencode; câu khác từ nhưng cùng nghĩa
CFG Scale (Sinh ảnh)	Điều chỉnh mức độ AI bám sát prompt	<i>generate images from text, increase specificity, reduce randomness, Stable Diffusion</i>	Tăng CFG Scale khi AI vẽ ảnh sản phẩm lung tung, không theo mô tả

 Nhóm 4: Hiệu Quả Kinh Doanh (Business & UX Metrics)

Dùng khi: Đánh giá tác động của AI đối với **doanh nghiệp** hoặc **người dùng**

Chỉ số	Tập trung vào	Keywords thi	Use case
Conversion Rate	Hành động thực tế mang lại lợi nhuận	<i>sales revenue, business impact, purchases</i>	Đánh giá Recommendation System – khách có mua hàng không
User Satisfaction	Trải nghiệm & cảm xúc người dùng	<i>UX, customer feedback, rating</i>	Đánh giá sự thân thiện của chatbot CSKH
Average Handling Time	Thời gian xử lý trung bình	<i>reduce time, AI efficiency, fewer tickets</i>	Đo hiệu quả AI trong quy trình hỗ trợ khách hàng

5. Tư Duy Business & Đánh Đổi (Trade-offs)

 AWS muốn ông bạn là một **Practitioner thực dụng** – không phải nhà nghiên cứu.

Tình huống	Ưu tiên
Chatbot CSKH trực tuyến	Latency thấp > Độ chính xác tuyệt đối (không để khách chờ 30 giây)
Ngân sách hạn chế	Dùng SLM (Small Language Models) hoặc Data Distillation thay vì mô hình khổng lồ
Cải thiện mô hình liên tục	Tích hợp User Feedback Loop (Like/Dislike) để thu thập dữ liệu cải thiện

 **Nguyên tắc:** AI không **thay thế** quy trình – AI **tối ưu hóa** quy trình.

6. Dịch Vụ AWS Managed AI – Chi Tiết Nâng Cao

Amazon Polly

- **Lexicons:** Tùy chỉnh cách phát âm từ viết tắt
- **SSML:** Điều khiển giọng điệu, nhấn nhá, tốc độ đọc

Amazon Rekognition

- **Face Liveness:** Phân biệt **mặt thật** với ảnh chụp / video giả mạo

Amazon Transcribe

- **Toxicity Detection:** Phát hiện ngôn từ độc hại
- **PII Redaction:** Tự động xóa thông tin cá nhân nhạy cảm

7. Amazon SageMaker – Công Cụ Chuyên Sâu

Công cụ	Chức năng
Data Wrangler	Chuẩn bị & biến đổi dữ liệu (Feature Engineering)
Feature Store	Kho lưu trữ trung tâm để chia sẻ và tái sử dụng features giữa nhiều mô hình

Deployment – Phân Biệt Hai Chế Độ

Chế độ	Đặc điểm	Khi nào dùng
Asynchronous Inference	File lớn tới 1GB , xử lý trong 1 giờ	Yêu cầu không cần phản hồi ngay lập tức
Batch Transform	Dự đoán cho toàn bộ tập dữ liệu ngoại tuyến	Xử lý hàng loạt, không cần real-time

8. Bảng Tra Cứu Nhanh – Chọn Metric Đúng Khi Thi

Từ khóa trong đề	Metric cần chọn
Dịch thuật, bilingual	BLEU
Tóm tắt văn bản	ROUGE
Teencode, từ đồng nghĩa, ngữ nghĩa	BERTScore
Sinh ảnh, bám sát prompt	CFG Scale
Spam, false alarm cao	Precision
Ung thư, bỏ lọt nguy hiểm	Recall
Dữ liệu mất cân bằng	F1 Score
Sai lệch lớn gây hậu quả	RMSE
Sai số trung bình chung	MAE
Mô hình nhầm ở đâu	Confusion Matrix
Khách hàng mua hàng	Conversion Rate
Người dùng hài lòng	User Satisfaction
AI trả lời sai định dạng	Few-shot Prompting
Bài toán logic/toán	Chain of Thought

 Tài liệu ôn tập AIF – Domain 3: Customization, Evaluation & Deployment