

AIF – Domain 2: Generative AI, LLM & Amazon Bedrock

1. Kiến Trúc Transformer – "Trái Tim" của LLM

Self-Attention Mechanism

Cơ chế giúp mô hình hiểu **mối quan hệ giữa các từ dù ở xa nhau** trong câu.

Ví dụ: Trong câu "Con mèo nằm trên thảm vì nó mệt", Self-Attention giúp AI biết **"nó"** đang ám chỉ **"con mèo"** chứ không phải **"cái thảm"**.

Encoder & Decoder

Thành phần	Chức năng	Mô hình tiêu biểu
Encoder	Hiểu ngữ cảnh đầu vào (input)	BERT
Decoder	Sinh nội dung đầu ra (output)	GPT, Claude
Encoder + Decoder	Kết hợp cả hai	T5, BART


⚠️ Lưu ý thi: Các LLM hiện đại như GPT và Claude đều dùng kiến trúc **Decoder-only**.

2. Foundation Models (FMs) trên Amazon Bedrock

So sánh các nhà cung cấp mô hình

Model	Nhà cung cấp	Điểm mạnh nổi bật
Amazon Titan	AWS	Tích hợp sẵn Responsible AI (lọc nội dung độc hại, bản quyền) – "nhà trồng" của AWS
Claude	Anthropic	Context Window cực lớn (200k+ tokens), suy luận phức tạp, viết code chuẩn
Llama	Meta	Mã nguồn mở (Open weights) – tùy chỉnh sâu, không phụ thuộc vendor đóng
Jurassic-2	AI21 Labs	Mạnh về đa ngôn ngữ và tuân thủ hướng dẫn phức tạp
Command / Embed	Cohere	Dòng Command cho text generation · Embed chuyên cho Embedding
Mistral	Mistral AI	Hiệu suất cực cao so với kích thước nhỏ (nhỏ nhưng có võ)
Stable Diffusion	Stability AI	Chuyên tạo hình ảnh từ văn bản

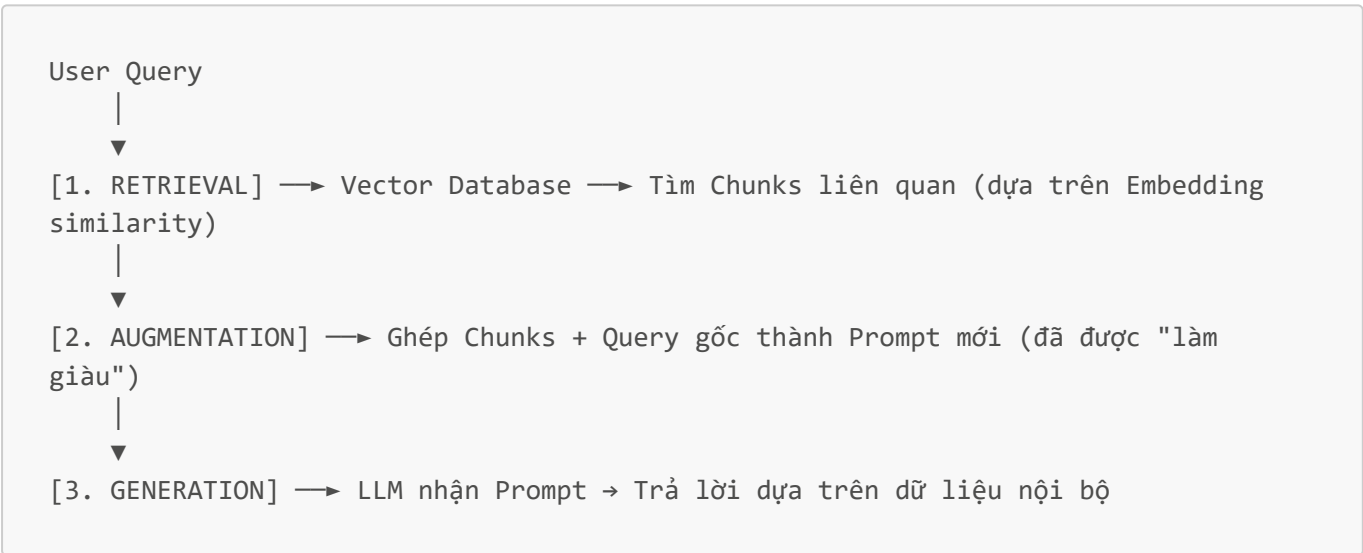
3. Cơ Chế Tạo Hình Ảnh – Diffusion Model



Giai đoạn	Mô tả
Forward Diffusion	Thêm nhiễu dần dần vào ảnh gốc cho đến khi trở thành nhiễu trắng hoàn toàn
Reverse Diffusion	Dựa trên prompt, mô hình khử nhiễu ngược để tái tạo ảnh mới có ý nghĩa

4. Quy Trình RAG – Retrieval-Augmented Generation

 **Câu hỏi Scenario-based phổ biến nhất trong thi AIF – phải nắm chắc!**



Lợi ích của RAG

Vấn đề	Giải pháp từ RAG
AI trả lời sai sự thật (Hallucination)	Cung cấp ngữ cảnh thực tế từ dữ liệu nội bộ
Dữ liệu lỗi thời	Cập nhật dữ liệu mới không cần train lại mô hình
Thiếu kiến thức chuyên ngành	Inject tài liệu nội bộ vào context

5. Inference Parameters – Điều Khiển Kết Quả Sinh

Dùng để kiểm soát tính **ngẫu nhiên (Non-deterministic)** của LLM.

Tham số	Giá trị thấp	Giá trị cao	Dùng cho
Temperature	Ổn định, chính xác, ít sáng tạo	Sáng tạo, bay bổng, đa dạng	Thấp: giải toán, trích xuất · Cao: viết văn, thơ
Top-P (Nucleus Sampling)	Chọn ít từ (xác suất tích lũy thấp)	Chọn nhiều từ hơn	Cân bằng sáng tạo & chính xác
Stop Sequences	—	—	Chuỗi ký tự để ra lệnh dừng trả lời

6. Tokenization & Chi Phí

Quy đổi Token

1,000 tokens ≈ 750 từ tiếng Anh

Cách AWS Bedrock tính tiền

Loại Token	Chi phí
Input Tokens	Rẻ hơn
Output Tokens	⚠ Đắt hơn input

Context Window

Nếu vượt quá giới hạn Context Window → AI sẽ **"quên"** phần đầu của hội thoại (bị tràn bộ nhớ).

- Claude: lên tới **200k+ tokens**
- Các mô hình khác: thường từ 4k → 32k tokens

7. Hallucination – Ảo Giác AI

Nguyên nhân

AI chỉ **đoán xác suất từ tiếp theo** – nó không thực sự "biết" sự thật.

Cách xử lý

Phương pháp	Mô tả
RAG	Cung cấp dữ liệu thực tế làm ngữ cảnh
Temperature thấp	Giảm ngẫu nhiên, tăng độ chính xác
Few-shot Prompting	Cung cấp ví dụ mẫu trong Prompt để định hướng câu trả lời

8. Các Dịch Vụ AI Của AWS – Phân Biệt Rõ

Amazon Q – Hai Phiên Bản

	Q Business	Q Developer
Mục tiêu	Doanh nghiệp	Lập trình viên & DevOps
Chức năng chính	Dùng dữ liệu nội bộ để trả lời câu hỏi	Viết code, quét lỗi bảo mật, quản lý AWS
Tích hợp	40+ connectors (S3, Salesforce, Microsoft 365...)	AWS Console, IDE
Quản lý hóa đơn	✗	✓ Phân tích chi phí AWS

PartyRock

 Chỉ là **Playground thử nghiệm** – không phải dịch vụ AWS chính thức và không cần tài khoản AWS để sử dụng.

9. Tóm Tắt Nhanh – Bảng Tra Cứu Khi Thi

Tình huống	Giải pháp
AI trả lời sai / bịa đặt	RAG + Temperature thấp
Cần tùy chỉnh mô hình sâu, không phụ thuộc vendor	Llama (Open weights)
Cần tạo hình ảnh từ văn bản	Stable Diffusion (Stability AI)
Cần embedding cho Vector DB	Cohere Embed / Amazon Titan Embeddings
Cần context window lớn	Claude (Anthropic)
Cần Responsible AI tích hợp sẵn	Amazon Titan
Dùng dữ liệu nội bộ công ty	Amazon Q Business
Hỗ trợ lập trình viên	Amazon Q Developer
Tạo ảnh qua AI	Diffusion Model (Forward → Reverse)

 Tài liệu ôn tập AIF – Domain 2: Generative AI, LLM & Amazon Bedrock