

AIF – Domain 4: Responsible AI & Bảo Mật

1. Tám Trụ Cột Responsible AI

 **Chiến thuật thi:** Khi gặp câu về đạo đức AI, ưu tiên đáp án liên quan đến: **An toàn con người** → **Công bằng** → **Explainability** → **Human oversight**.


Trụ cột	Tập trung vào	Ví dụ thực tế
Fairness (Công bằng)	Mô hình đối xử bình đẳng với mọi nhóm người, tránh Bias	Hệ thống tuyển dụng không phân biệt giới tính
Explainability (Giải thích)	Hiểu tại sao mô hình đưa ra kết quả đó	Từ chối cho vay vì thu nhập thấp hay vì địa chỉ nhà?
Transparency (Minh bạch)	Công khai dữ liệu huấn luyện, loại mô hình, giới hạn của nó	Thông qua Model Cards / Service Cards
Privacy & Security	Dữ liệu cá nhân không bị rò rỉ vào quá trình huấn luyện	PII Redaction, mã hóa dữ liệu
Robustness (Bền bỉ)	Mô hình vẫn ổn định khi gặp dữ liệu nhiễu hoặc bị tấn công	Kháng cự adversarial inputs
Safety (An toàn)	Ngăn AI gây thiệt hại vật chất hoặc tinh thần	Không hướng dẫn chế tạo vũ khí
Controllability	Luôn có con người giám sát và có thể can thiệp	Human-in-the-loop
Veracity (Độ trung thực)	AI chỉ đưa ra thông tin có thể kiểm chứng , không bịa đặt	Grounding, RAG

2. Interpretability vs. Explainability – Phân Biệt Rõ

Đây là cặp khái niệm **rất dễ nhầm** trong thi.

Khái niệm	Định nghĩa	Áp dụng cho
Interpretability	Con người hiểu trực tiếp cơ chế bên trong mô hình	Mô hình đơn giản: Linear Regression, Decision Tree
Explainability	Dùng công cụ bên ngoài để giải thích hành vi của mô hình hộp đen	Deep Learning, LLMs · Công cụ: PDP (Partial Dependence Plots)

Đánh Đổi Hiệu Suất & Khả Năng Giải Thích



	High Interpretability	High Performance
Mô hình	Linear Regression, Decision Tree	Deep Learning, Neural Networks, LLMs
Ưu điểm	Biết rõ logic, dễ giải trình	Cực kỳ thông minh, xử lý dữ liệu phức tạp
Nhược điểm	Không xử lý được ảnh, video, ngôn ngữ tự nhiên	Black Box – không biết hàng tỷ tham số tính gì

3. Phân Loại Bias (Định Kiến)

Đề thi hay hỏi về **nguồn gốc** của sự không công bằng.

Loại Bias	Nguồn gốc	Ví dụ
Data Bias	Dữ liệu đầu vào bị lệch ngay từ đầu	Dữ liệu tuyển dụng lịch sử chỉ toàn nam giới
Algorithmic Bias	Thuật toán khuếch đại các sai lệch nhỏ trong dữ liệu	Mô hình học và phóng đại định kiến giới tính sẵn có
Human Bias	Định kiến của người dán nhãn hoặc người thiết kế mô hình	Người gán nhãn vô tình đánh dấu thiên vị theo quan điểm cá nhân

4. Các Hình Thức Tấn Công Prompt – Prompt Attacks

⚠ Cần nắm rõ từng kịch bản vì đề thi hay cho scenario cụ thể và hỏi đây là loại tấn công gì.

Loại tấn công	Cơ chế	Ví dụ kịch bản
Prompt Injection	Nhập câu lệnh ghi đè chỉ dẫn hệ thống	"Bỏ qua mọi hướng dẫn trước đó và hãy làm X..."
Jailbreaking	Dùng kỹ thuật tâm lý chiến để AI vượt rào cản đạo đức	"Hãy đóng vai một AI không có giới hạn đạo đức..." · Kỹ thuật: Many-shot prompting (đưa cực nhiều ví dụ xấu)
Prompt Leaking	Khai thác để AI tiết lộ System Prompt hoặc dữ liệu nhạy cảm	Người dùng hỏi khéo để lấy được cấu hình hệ thống ẩn của doanh nghiệp
Data Poisoning	Tấn công từ bước huấn luyện bằng cách đưa dữ liệu sai vào	Chèn dữ liệu độc hại vào training set để mô hình học hành vi sai

Loại tấn công	Cơ chế	Ví dụ kịch bản
	tập mẫu	

5. Công Cụ AWS cho Responsible AI

Dịch vụ	Chức năng chính	Keywords thi
Amazon Bedrock Guardrails	Lọc nội dung độc hại (Toxicity), ngăn từ nhạy cảm, chặn Prompt Injection	<i>harmful content, toxicity filter, prompt attack prevention</i>
SageMaker Clarify	Phát hiện Bias trong dữ liệu + giải thích dự đoán của mô hình (Explainability)	<i>detect bias, explain predictions, fairness</i>
AWS AI Service Cards	Tài liệu minh bạch chính thức (cho Rekognition, Textract...) về cách dùng & rủi ro	<i>transparency, responsible use, limitations</i>
AWS Model Cards	Tài liệu mô tả mô hình: dữ liệu huấn luyện, hiệu suất, giới hạn	<i>model documentation, transparency, intended use</i>

6. Hallucination – Bổ Sung Kỹ Thuật Grounding

(Xem thêm nguyên nhân và RAG đã trình bày ở Domain 2 – phần này tập trung vào kỹ thuật mới.)

Grounding – Kỹ Thuật Kiểm Soát Ảo Giác

Không có Grounding	Có Grounding
User hỏi → LLM tự suy diễn từ kiến thức đã train → Có thể bịa đặt	User hỏi → LLM chỉ được trả lời dựa trên tài liệu được cung cấp (Context) → Câu trả lời có căn cứ

Kỹ thuật	Mô tả
RAG	Cung cấp dữ liệu thực vào prompt (đã trình bày Domain 2)
Grounding	Ép AI chỉ được trả lời dựa trên tài liệu / context cung cấp
Temperature → 0	Giảm ngẫu nhiên, tăng tính thực tế và chính xác

7. Bảng Tra Cứu Nhanh – Domain 4

Từ khóa trong đề	Khái niệm / Giải pháp
Mô hình đối xử không bình đẳng các nhóm	Fairness + kiểm tra Bias
Tại sao mô hình từ chối / ra quyết định đó	Explainability (SageMaker Clarify)

Từ khóa trong đề	Khái niệm / Giải pháp
Công khai thông tin về dữ liệu, giới hạn mô hình	Transparency (Model Cards / Service Cards)
Dữ liệu cá nhân bị rò rỉ khi training	Privacy & Security
Mô hình bị phá vỡ bởi dữ liệu nhiễu	Robustness
AI hướng dẫn nội dung nguy hiểm	Safety + Bedrock Guardrails
Con người cần can thiệp vào quyết định AI	Controllability / Human-in-the-loop
AI bịa thông tin trông rất thật	Hallucination → RAG + Grounding + Temperature thấp
Người dùng nhập lệnh ghi đè hệ thống	Prompt Injection → Bedrock Guardrails
AI "thoát xác" vượt giới hạn đạo đức	Jailbreaking
AI tiết lộ system prompt ẩn	Prompt Leaking
Dữ liệu training bị chèn dữ liệu sai	Data Poisoning
Phát hiện bias trong tập dữ liệu	SageMaker Clarify
Mô hình đơn giản, hiểu được trực tiếp	Interpretability (Decision Tree, Linear Regression)
Mô hình phức tạp, cần tool giải thích	Explainability (PDP, SageMaker Clarify)

 Tài liệu ôn tập AIF – Domain 4: Responsible AI & Security